

Contexto del Proyecto

InsightReach es una empresa de marketing digital especializada en campañas personalizadas para negocios locales. Este proyecto tiene como objetivo integrar múltiples fuentes de datos para generar insights accionables que apoyen la toma de decisiones de negocio en el sector gastronómico de Chicago.

2. Fuentes de Datos

Dataset de Encuestas (base_datos_restaurantes_USA_v2.csv)

- 30,000 registros de clientes en 10 ciudades de EE.UU.
- 17 columnas: datos demográficos, hábitos de consumo y preferencias alimenticias.
- Ciudad de análisis seleccionada: Chicago (5,384 registros).

API de Yelp Fusion

- Conexión mediante requests a <https://api.yelp.com/v3/businesses/search>
- Se extrajeron hasta 200 restaurantes de Chicago con limit=50 y offset paginado.
- Campos obtenidos: nombre, categoría, calificación, número de reseñas, precio y dirección.
- Total de registros obtenidos: 325 (por límite de la API en plan gratuito).

3. Proceso de Limpieza (Avance 1)

Columna	Problema	Solución
edad	Valor centinela -5 (97 registros)	Reemplazar por NaN, imputar con mediana
edad	Error de captura 300 (110 registros)	Reemplazar por NaN, imputar con mediana
frecuencia_visita	Valor centinela -3 (1,547 registros)	Reemplazar por NaN, imputar con mediana
preferencias_alimenticias	Nulos (1,403 registros)	Rellenar con "No especificado"
promedio_gasto_comida	Valor 0 (1,463 registros)	Se conserva como cortesía del restaurante
teléfono / correo	Nulos masivos (+15,000)	Se ignoran por ser irrelevantes para el análisis

4- Análisis Exploratorio de Datos — Chicago

Se analizaron 5,384 registros correspondientes a la ciudad de Chicago, explorando variables demográficas y de comportamiento. La distribución por género resultó casi equitativa (50.45% masculino, 49.55% femenino), con una base de clientes predominantemente adulta de mediana edad (promedio 48.7 años) distribuida uniformemente entre los 18 y 80 años.

En cuanto al poder adquisitivo, se identificaron cuatro estratos socioeconómicos (Bajo, Medio, Alto y Muy Alto), con una relación directamente proporcional entre estrato y gasto promedio en restaurantes, que va desde \$5.80 en estrato Bajo hasta \$54.17 en estrato Muy Alto. El análisis de preferencias alimenticias mostró que las Carnes son la categoría dominante, seguida de Vegetariano y Mariscos.

Se analizaron además variables de comportamiento como membresía premium (41.14% de los clientes) y consumo de licor (62.7%), encontrando que los consumidores de licor tienden a ser más jóvenes con una mediana de 47 años vs 52 años en no consumidores. Todas las visualizaciones se realizaron con matplotlib y seaborn bajo una paleta de colores unificada sobre fondo oscuro.

5. Integración API de Yelp (Avance 2)

- **Extracción de datos**

Se utilizó un loop while con paginación (offset de 0 a 150) para obtener restaurantes de Chicago. La respuesta JSON fue procesada con `pd.json_normalize()` usando `record_path='categories'` para desanidar las categorías y obtener una fila por categoría por restaurante.

- **Estandarización de categorías**

Se creó un diccionario de mapeo para alinear las categorías de Yelp con las preferencias del dataset de encuestas:

- **Vegetariano/Vegano:** Salad, Mediterranean, Asian Fusion, Thai, Pizza, Italian
- **Mariscos/Pescado:** Seafood, Ramen, Izakaya, Japanese, Noodles
- **Carnes:** Steakhouses, Burgers, Mexican, Tacos, Breakfast & Brunch, entre otros
- **Otro:** Bares, Breweries, Karaoke, Venues y demás categorías no alimenticias

Rating Ponderado (Fórmula IMDb)

Para evitar que restaurantes con pocas reseñas pero alto rating dominen las recomendaciones, se aplicó la fórmula de rating ponderado:

$(v / (v + m)) * R + (m / (v + m)) * C$, donde v = reseñas del restaurante, m = 500 (factor de penalización), R = rating del restaurante y C = 4.42 (rating promedio global).

6. Sistema de Recomendaciones

Se generaron dos tablas de recomendaciones integradas en el Avance 1:

- **df_chicago_recomendaciones:** cada cliente de Chicago recibe el restaurante con mayor rating ponderado que coincide con su preferencia alimenticia estandarizada.
 - **top3_por_categoria:** los 3 mejores restaurantes por categoría, disponibles como alternativas de recomendación para cada segmento.
-

7. Stack Técnico

- **Lenguaje:** Python 3
- **Librerías:** pandas, numpy, matplotlib, seaborn, requests
- **API:** Yelp Fusion API (plan gratuito)
- **Entorno:** Jupyter Notebook
- **Notebooks:** Avance_1_EDA.ipynb | Avance_2_API_Yelp.ipynb